

Maintenance Prédicative Aéronautique par Intelligence Artificielle

Rapport Technique Projet Universitaire

Réalisé par : Nassira FAHFOUHI et Noura KAZDARI

Institution : ENSA Safi | Département GINF | GATE3

Date : 22 Décembre 2025

Domaine : Maintenance Prédicative, Machine Learning Industriel, Aéronautique

1. Introduction & Contexte Industriel

1.1 Importance de la Maintenance en Aéronautique

L'industrie aéronautique moderne (Airbus, Boeing, Safran, GE Aviation) fait face à un enjeu stratégique majeur : **la maintenance représente 10-15 % des coûts d'exploitation totaux d'une compagnie aérienne**. Au-delà du coût, la maintenance est intrinsèquement liée à la sécurité des passagers. Chaque défaillance non détectée accroît le risque d'incident catastrophique en vol.

La gestion de la maintenance d'une flotte de plusieurs centaines d'aéronefs exige une optimisation constante entre :

- Sécurité opérationnelle** (impératif absolu)
- Disponibilité de la flotte** (maximiser les heures de vol productive)
- Coûts de maintenance** (réduire les dépenses sans compromettre la sécurité)

1.2 Comparaison des Stratégies de Maintenance

Type de maintenance	Concept	Avantages principaux	Inconvénients / limites	Remarque aéronautique
Maintenance corrective (réactive)	Réparer uniquement après panne ou défaillance détectée.	Coûts visibles réduits à court terme.	Inacceptable pour la sécurité, pannes en cascade, immobilisation imprévisible, coûts cachés élevés, non conforme aux normes (DO-254, DO-178C, AS9100).	Stratégie à éviter pour les systèmes critiques.
Maintenance préventive (systématique)	Remplacement à intervalles fixes définis par le constructeur (ex. toutes les 5 000 h).	Moins de pannes inattendues, planification facile, conformité réglementaire.	Surcoût important, remplacement de pièces encore bonnes, arrêts fréquents, pas d'adaptation au profil réel d'usage.	Modèle encore très utilisé mais peu optimisé.
Maintenance prédictive (objectif du projet)	Utiliser les données capteurs pour prévoir le moment optimal d'intervention avant la défaillance.	Intervention « juste à temps », réduction des coûts, sécurité accrue, alignée avec l'industrie 4.0.	Nécessite capteurs fiables, infrastructure Big Data et modèles RUL robustes.	Approche recommandée pour moteurs et systèmes critiques modernes.

1.3 Remaining Useful Life (RUL) - Concept Central

Le **RUL (Durée de Vie Restante)** est le nombre de cycles de fonctionnement (ou heures de vol) restant avant la défaillance critique d'un composant.

Exemple concret :

- Un turboréacteur atteint généralement sa fin de vie utile après 40 000 cycles.
- Au cycle 30 000, le **RUL = 40 000 - 30 000 = 10 000 cycles restants**.
- À partir des paramètres opérationnels et capteurs, notre modèle doit estimer ce RUL avec précision.

Impact industriel :

- Prédire RUL avec une marge d'erreur < 5 % permet des gains annuels de **millions d'euros** par flotte.
- Chaque jour d'immobilisation non planifiée coûte 100 000 – 500 000 € en pertes de chiffre d'affaires.

2. Description du Dataset NASA C-MAPSS

2.1 Origine et Contexte

Le dataset **C-MAPSS (Commercial Modular Aero-Propulsion System Simulation)** est un benchmark de référence dans la communauté scientifique de la maintenance prédictive. Il a été développé par la NASA et le centre de recherche aeronautique et est devenu un standard de validation pour tous les algorithmes de prédiction RUL en aéronautique.

Caractéristiques du dataset :

- **Type** : Données synthétiques simulant l'usure réaliste de moteurs commerciaux
- **Générateur** : Simulateur CMAPSS de la NASA Ames Research Center
- **Représentativité** : Reproduit fidèlement la dégradation progressive d'un vrai moteur

2.2 Structure du Dataset FD001

Le dataset se compose de trois fichiers textes distincts :

Fichier d'Entraînement : train_FD001.txt

Contenu : Historique complet de 100 turboréacteurs observés du moment de leur mise en service jusqu'à défaillance complète.

Dimension : 20 631 lignes × 26 colonnes (chaque ligne = une observation à un cycle donné)

Structure des colonnes :

Tableau 1 : Structure du fichier train_FD001.txt

Colonne	Nom	Type	Description
1	engine_id	Entier	Identifiant unique du moteur (1-100)
2	cycle	Entier	Numéro du cycle d'opération (temps discret)
3-5	Setting 1, 2, 3	Float	Paramètres opérationnels (altitude, Mach, manette)
6-26	Sensor 1-21	Float	Mesures des 21 capteurs (T2, P2, Nf, etc.)

Interprétation physique des paramètres opérationnels :

- **Setting 1** : Altitude de vol ou Mach number (varie entre 0 et 42)
- **Setting 2** : Angle d'attaque ou configuration du moteur (-0.0087 à 0.0087)
- **Setting 3** : Position manette des gaz (thrust setting) (100.0 à 100.0 en condition nominale)

Fichier de Test : test_FD001.txt

Contenu : 13 896 lignes de 100 moteurs additionnels (différents des moteurs d'entraînement) observés jusqu'à un instant critique t , sans avoir atteint la défaillance.

Objectif de prédiction : Pour chaque moteur au dernier cycle observé, prédire le nombre de cycles restants avant défaillance.

Fichier de Vérité : RUL_FD001.txt

Contenu : Les vraies valeurs RUL pour les 100 moteurs du dataset test (une valeur par ligne).

Utilisation : Validation et calcul des métriques d'erreur (RMSE).

2.3 Description des Capteurs

Les 21 capteurs mesurent des paramètres physiques critiques du turboréacteur :

Capteurs de Température :

- T2 : Température air entrée fan (Low Pressure Compressor Inlet)
- T24 : Température interétage compresseur basse pression
- T30 : Température sortie fan (High Pressure Compressor Inlet)
- T50 : Température interétage compresseur haute pression
- P2, P15, P30 : Pressions correspondantes
- LPCOutletT, HPC Outlet T : Températures de sortie des étages compresseurs

Capteurs de Vitesse de Rotation :

- Nf : Vitesse fan (tours par minute)
- Nc : Vitesse compresseur haute pression

Capteurs Auxiliaires :

- BPR : Bypass Ratio (rapport air de dérivation)
- W31, W32 : Débits de carburant

Indicateurs de Performance :

- Ratio : Rapport de performance relatif

Cette instrumentation dense permet une surveillance multiparamétrique de l'état du moteur et fournit un signal riche pour l'apprentissage du modèle.

3. Analyse Exploratoire des Données (EDA)

3.1 Chargement et Inspection des Données

Les données brutes ne contiennent pas d'en-têtes. Après chargement, les 100 moteurs d'entraînement affichent :

Résumé statistique :

- Moteur 1 à 100 : cycles de 1 à 362 cycles maximum

- Tous les moteurs terminent par une défaillance (le dataset d'entraînement est complet)
- 21 capteurs avec des distributions très hétérogènes (certains constants, d'autres hautement variables)

3.2 Évolution des Capteurs Sélectionnés

L'observation graphique de la dégradation moteur pour plusieurs moteurs révèle des comportements distincts :

Moteur 69 (dégradation longue) :

- **Observation** : Le RUL diminue linéairement au cours de 350 cycles (usure progressive régulière)
- **Pattern** : Capteurs de température augmentent graduellement, indiquant accumulation de friction et usure thermique
- **Interprétation physique** : Moteur fonctionnant dans des conditions nominales, dégradation thermique normale

Moteur 8 (dégradation rapide) :

- **Observation** : Le RUL chute sur seulement 140 cycles (usure accélérée)
- **Pattern** : Pics et instabilités dans les capteurs de pression et température
- **Interprétation physique** : Moteur opérant en condition critique ou dégradée (fonctionnement en limite d'enveloppe)

Moteur 54 (dégradation modérée) :

- **Observation** : Pattern intermédiaire, RUL linéaire sur ~250 cycles
- **Capteurs** : Évolution régulière mais avec variabilité accrue vers la fin de vie

3.3 Identification des Capteurs Constants (Non-Informatifs)

Découverte critique : Certains capteurs affichent une **variance quasi-nulle** sur tout le dataset.

Tableau 2 : Exemple : Variance et pertinence des capteurs

Capteur	Écart-type	Décision
Setting_1	14.56	Conservé
Setting_2	0.001	Supprimé
Setting_3	0.001	Supprimé
s1	518.67	Conservé
s5	14.62	Conservé
s10	1.300	Supprimé
s16	0.030	Supprimé
s18	2388.00	Conservé
s19	100.00	Conservé

Justification de suppression :

- Les capteurs avec écart-type < 1 n'apportent aucune variation dans les données
- Ils augmentent la dimensionnalité sans ajouter d'information (curse of dimensionality)
- En ML, plus de features $\neq$ meilleur modèle (risque d'overfitting)

3.4 Matrice de Corrélation entre Capteurs

L'analyse de corrélation révèle :

Corrélations fortes (> 0.9) :

- T2 & T24 : corrélation = 0.95 (redondance : mesures de température complémentaires)
- Nf & Nc : corrélation = 0.92 (à considérer : peut-on éliminer l'une ?)
- P30 & T30 : corrélation = 0.89 (pression et température liées thermodynamiquement)

Interprétation physique :

- Les hautes corrélations sont **attendues en aéronautique** (les paramètres physiques du moteur sont intrinsèquement couplés)
- On ne supprime pas les capteurs corrélés car chacun apporte une information complémentaire en contexte multivarié
- L'algorithme Random Forest gère naturellement les corrélations (contrairement à la régression linéaire)

Corrélations avec le RUL (cible) :

- s11 : corrélation = -0.44 (forte relation inversée : plus haut s11, plus faible RUL)
- s4 : corrélation = -0.35
- s9 : corrélation = -0.31

Ces capteurs sont **les plus prédictifs** du RUL et doivent absolument être conservés.

4. Prétraitement & Feature Engineering

4.1 Calcul du Remaining Useful Life (RUL)

Problème : Le fichier d'entraînement ne contient pas de colonne RUL. Or, c'est notre cible (label) d'apprentissage.

Logique d'implémentation :

1. Pour chaque moteur (engine_id), identifier le **cycle maximum** (dernier cycle avant défaillance)
2. Pour chaque ligne, calculer : $RUL = \text{max_cycle} - \text{cycle_actuel}$
3. Ajouter la colonne résultante au DataFrame d'entraînement

Exemple concret :

- Moteur 1 : max_cycle = 192
 - Cycle 1 : $RUL = 192 - 1 = 191$
 - Cycle 100 : $RUL = 192 - 100 = 92$
 - Cycle 192 : $RUL = 192 - 192 = 0$ (défaillance)

Cette approche garantit que le modèle apprend une relation directe : "**à tel état du moteur (capteurs), il reste X cycles**".

4.2 Nettoyage des Features

Étapes de nettoyage :

1. **Suppression de l'identifiant moteur** : engine_id
 - Raison : L'ID est un identifiant administratif, pas une variable prédictive
 - Le modèle ne doit pas apprendre des patterns spécifiques à un moteur particulier (risque d'overfitting)
2. **Suppression du numéro de cycle** : cycle

- Raison : Bien que le cycle soit une information temporelle, le laisser dans les features créerait une **fuite d'information** (leakage)
 - Le modèle devrait prédire RUL à partir des **états des capteurs**, pas du simple compt du temps
 - Inclusion de cycle → modèle trivial : $RUL \approx \text{const} - \text{cycle}$ (non générique)
3. **Suppression des capteurs constants** : (liste établie en section 3.3)
- Setting_2, Setting_3, s10, s16, etc.
 - Variance ≈ 0 → aucune contribution à la prédiction

Résultat après nettoyage :

- Features originales : 25 (engine_id + cycle + 3 paramètres + 21 capteurs)
- Features finales conservées : **17 capteurs** informatifs
- Réduction dimensionnalité : 32 % (élimine le bruit sans perdre le signal)

4.3 Normalisation Min-Max

Problème : Les 17 capteurs ont des **unités et plages de valeurs très différentes** :

- T2 (température) : plage [500, 650] °C
- P2 (pression) : plage [14, 15] psi
- Nf (vitesse fan) : plage [1300, 2400] tours/min
- W31 (débit) : plage [0.001, 0.1]

L'IA (algorithmes de distance, gradients) est **sensible à l'échelle** des variables. Sans normalisation :

- Features à grande magnitude dominant l'apprentissage
- Convergence lente
- Interprétabilité réduite

Formule Min-Max (utilisée) :

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Résultat : Tous les capteurs sont ramenés à l'intervalle [0,1] de manière uniforme.

Choix de Min-Max plutôt que Standardisation (Z-score) :

- Min-Max préserve la **distribution originale** (utile pour analyser les résultats)
- Z-score décale la moyenne à 0 et écart-type à 1 (moins intuitif pour l'aéronautique)
- Dans ce projet, Min-Max offre meilleure interprétabilité physique

4.4 Résumé : Dataset Prétraité

Après toutes les transformations :

Dataset d'entraînement :

- 20 631 lignes (observations)
- 17 colonnes de features (capteurs informatifs)
- 1 colonne cible : RUL (0 à ~400 cycles)
- Pas de valeurs manquantes

- Toutes variables normalisées à [0, 1]

Dataset de test :

- 13 896 lignes (100 moteurs, leurs derniers cycles)
 - Mêmes 17 features (appliquées les mêmes statistiques de normalisation)
 - Cible RUL à prédire
-

5. Modélisation Machine Learning

5.1 Choix des Modèles

Nous avons testé et comparé **deux approches** représentant les paradigmes clés du ML :

Approche 1 : Baseline - Régression Linéaire

Modèle : LinearRegression (scikit-learn)

Hypothèse sous-jacente : RUL est une fonction linéaire des 17 capteurs normalisés

$$\text{RUL} = w_0 + w_1 \cdot s_1 + w_2 \cdot s_2 + \dots + w_{17} \cdot s_{17}$$

Justification du choix :

- Baseline simple et rapide (référence de comparaison)
- Offre des **coefficients interprétables** (quel capteur influence le RUL ?)
- Calcul léger, sans hyperparamètres
- Permet d'évaluer si le problème a une **relation linéaire** ou non

Limitations acceptées :

- Peu flexible pour capurer les interactions complexes entre capteurs
- Assume une relation monotone (réalité : relations non-linéaires)

Approche 2 : Avancée - Random Forest Regressor

Modèle : RandomForestRegressor (scikit-learn, n_estimators=200)

Concept : Ensemble d'**arbres de décision** indépendants. Chaque arbre segmente l'espace des features de manière non-linéaire pour prédire RUL. Les prédictions sont moyennées (ensemble learning).

Hyperparamètres choisis :

- `n_estimators = 200` : 200 arbres dans la forêt (balance variance-biais)
- `max_depth = None` : Arbres non limités en profondeur (flexibilité maximale)
- `min_samples_leaf = 5` : Chaque feuille doit contenir ≥ 5 observations (régularisation)

Justification du choix :

- **Non-linéarité** : Capture facilement les interactions complexes entre capteurs
- **Robustesse** : Insensible aux outliers et aux capteurs corrélés
- **Performance empirique** : Standard industriel pour la prédiction RUL (benchmark NASA)
- **Interprétabilité** : Permet l'extraction de feature importances

Avantages vis-à-vis de la régression linéaire :

- Modèle plus puissant (flexibilité accrue)
- Gestion naturelle des seuils et des non-linéarités
- Moins sujet aux hypothèses restrictives

5.2 Séparation Train/Validation

Division des données :

- **Training set** : 80 % du dataset train (16 504 observations)
- **Validation set** : 20 % du dataset train (4 127 observations)
- **Test set** : 100 % du dataset test (13 896 observations, labels externes)

Stratégie de séparation :

- Random shuffle avec `random_state=42` (reproductibilité)
- Division stratifiée non utilisée (RUL est continu, pas discret)

5.3 Entraînement des Modèles

Régression Linéaire :

`X_train.shape = (16504, 17)`

`y_train.shape = (16504,)`

Temps d'entraînement : < 0.1 seconde

Paramètres appris : 17 poids + 1 biais

Random Forest :

`X_train.shape = (16504, 17)`

`y_train.shape = (16504,)`

Temps d'entraînement : ~10-15 secondes (200 arbres)

Hyperparamètres : `n_estimators=200`, `max_depth=None`, `min_samples_leaf=5`

Seed : 42

5.4 Prédictions et Évaluation

Sur le dataset de test :

1. Régression Linéaire :

○ $RMSE_{baseline} = 41.32$ cycles

2. Random Forest :

○ $RMSE_{best} = 41.16$ cycles

Observation : Les deux modèles affichent des performances très proches (~41 cycles d'erreur moyenne). Cela indique que **la relation RUL-capteurs n'est pas fortement non-linéaire**. Cependant, le Random Forest offre une légère supériorité (0.4 % d'amélioration).

6. Évaluation & Résultats

6.1 Métrique RMSE (Root Mean Square Error)

Définition :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

où $\hat{y}_i$ = RUL prédit, y_i = RUL réel, n = nombre de moteurs test.

Interprétation :

- RMSE = 41 cycles signifie que le modèle se trompe en moyenne de **41 cycles** (sur un RUL max de ~400 cycles)
- **Erreur relative** : $41/400 \approx 10 \%$ (acceptable pour une première approche)

Comparaison avec les standards industriels :

- Baseline acceptable : RMSE < 50 cycles (25 % de marge)
- Bon modèle : RMSE < 30 cycles (15 % de marge)
- Excellent modèle : RMSE < 20 cycles (5 % de marge)

Notre approche atteint **RMSE $\approx$ 41**, classant le modèle comme **acceptable mais avec marge d'amélioration**.

6.2 Comparaison des Modèles

Tableau 3 : Tableau comparatif des performances

Modèle	RMSE (Test)	Temps Entraînement	Interprétabilité
Régression Linéaire	41.32 cycles	< 0.1 s	Excellente
Random Forest	41.16 cycles	~15 s	Bonne

Analyse critique :

1. **Régression Linéaire** (41.32 cycles) :
 - Performance quasi-identique au Random Forest
 - Coûts computationnels minimaux
 - Coefficients directs interprétables
2. **Random Forest** (41.16 cycles) :
 - Amélioration marginale (-0.4 %)
 - Coûts computationnels plus élevés (100×)
 - Interprétabilité via feature importances

Recommandation opérationnelle :

- Pour un **déploiement production**, la Régression Linéaire suffisait (temps réel critique)
- Pour une **amélioration continue**, le Random Forest offre un levier futur

6.3 Analyse des Prédictions par Moteur

Moteur 69 (exemple : dégradation longue) :

- RUL réel final : 350+ cycles
- RUL prédit : 355 cycles

- Erreur : < 2 %
- **Conclusion** : Prédiction excellente pour moteur "nominal"

Moteur 8 (exemple : dégradation rapide) :

- RUL réel final : 140 cycles
- RUL prédit : 150 cycles
- Erreur : ~7 %
- **Conclusion** : Légère surestimation du RUL pour moteur dégradé

Moteur 54 (exemple : dégradation modérée) :

- RUL réel final : 250 cycles
- RUL prédit : 245 cycles
- Erreur : ~2 %
- **Conclusion** : Bonne performance moyenne

Pattern observé : Le modèle prédit avec plus de précision les moteurs en condition nominale, et légèrement moins bien les moteurs en dégradation accélérée (où la non-linéarité est plus forte).

6.4 Feature Importance (Random Forest)

L'extraction des importances du modèle Random Forest révèle les capteurs les plus influents :

Tableau 4 : Feature importances du Random Forest (top 6)

Feature (Capteur)	Importance	Rang
s11	0.4447	1
s4	0.1353	2
s9	0.1310	3
s12	0.0493	4
s7	0.0326	5
s14	0.0317	6
(autres capteurs)	0.0154	7-17

Interprétation physique :

- **s11 (dominante à 44.5%)** : Probablement un indicateur de performance hydraulique ou thermique très sensible à l'usure
- **s4, s9** : Capteurs de température ou pression additionnels, fortement corrélés avec la dégradation

Implication : Si ressources limitées, surveiller prioritairement **s11, s4, s9** suffirait à 70 % de la prédiction du modèle.

7. Discussion Industrielle & Limites

7.1 Faisabilité d'Intégration en Avion Réel

Question critique : Ce modèle peut-il être déployé sur des aéronefs en opération?

Conditions requises pour un passage en production :

A) Certification Aéronautique (DO-254, DO-178C)

Le code et le modèle doivent être certifiables par les autorités aéronautiques (EASA, FAA).

Exigences :

- Architecture documentée et validée
- Tests de robustesse sur 10 000+ cycles réels
- Analyse FMEA (Failure Mode Effects Analysis) de chaque décision du modèle
- Validation que le modèle ne dépense pas le temps de calcul impartible

Statut actuel : NON CERTIFIABLE (modèle basé sur simulations, pas données réelles)

B) Qualité des Données

Les données d'entraînement (NASA C-MAPSS) sont **synthétiques et idéalisées**.

Différences vis-à-vis des données réelles :

- Absence de **bruit capteur** (défaillances intermittentes, calibration dérivée)
- Pas de **variabilité environnementale** réelle (température extérieure, humidité, altitude)
- Pas de **modes de dégradation anormaux** (craquement de lame, corrosion côtière)
- Dataset "propre" (pas d'outliers, pas d'anomalies)

Risque majeur : Un modèle entraîné sur données synthétiques perfectionnées peut s'effondrer en environnement réel bruyant.

C) Latence et Calculabilité

Exigence : Calcul du RUL en **temps réel**, avec latence < 100 ms (pendant le vol ou au sol).

Capacité du modèle :

- Régression linéaire : ~0.01 ms (embarquable facilement)
- Random Forest (200 arbres) : ~10 ms (acceptable)

Verdict : ✓ Latence acceptable pour avionique embarquée

7.2 Risques et Scénarios Critiques

Scénario 1 : Capteur Défaillant

Situation : Un des 17 capteurs cesse de fonctionner (perte de signal ou saturation).

Impact :

- Prédiction RUL devient **invalidé** (perte d'information)
- Risque : Surestimation du RUL (pas d'alerte défaillance)

Mitigation :

- Ajouter un **capteur de redondance** (duplication des 3 capteurs les plus importants : s11, s4, s9)
- Monitorer la cohérence des capteurs (détection anomalies)
- Fallback à seuils fixes si un capteur échoue

Scénario 2 : Déviation Opérationnelle

Situation : Le moteur opère en **conditions anormales** (p.ex. pattern d'usure anormal, dégivrage prolongé, montée accélérée).

Impact :

- Modèle entraîné sur données nominales → **extrapolation dangereuse**
- Prédiction RUL erronée

Mitigation :

- Ajouter un **détecteur d'anomalies** (One-Class SVM, Isolation Forest)
- Signaler si les capteurs sortent de la distribution d'entraînement
- Avertir le pilote / maintenance si RUL devient imprévisible

Scénario 3 : Données Bruitées (Capteurs Imprécis)

Situation : Capteurs produisent des bruits parasites (électroniques, vibrations, défaillances transitoires).

Impact :

- Prédiction RUL devient noisy et instable
- Risque : Fausses alertes de maintenance

Mitigation :

- Appliquer un **filtre Kalman** ou lissage temporel sur les capteurs
- Augmenter les données d'entraînement avec bruit synthétique (data augmentation)
- Tester la robustesse du modèle à des bruits de $\pm 10\%$

7.3 Améliorations Futures

1. Deep Learning (LSTM/Temporal Models)

Limitation actuelle : Modèles sans mémoire temporelle. Chaque cycle d'observation est indépendant.

Approche Deep Learning :

- **LSTM (Long Short-Term Memory)** : Réseau de neurones récurrent capable de mémoriser la **trajectoire temporelle** du moteur
- Entrée : Séquence temporelle de 50 cycles précédents
- Sortie : Prédiction RUL

Avantage : Capture des **patterns temporels** (accélération de dégradation, cycles de fatigue)

Exemple :

- Moteur 8 : dégradation rapide → LSTM détecte "accélération" → alerte précoce
- Moteur 69 : dégradation linéaire → LSTM prédiction plus stable

Coût : Augmente significativement la complexité et les exigences de données.

2. Données Réelles et Transfer Learning

Limitation : Données synthétiques (gap réalité-simulation).

Approche Transfer Learning :

- Collecter données réelles d'une compagnie aérienne (confidentielles mais accessibles)
- Pré-entraîner sur C-MAPSS (synthétique)
- Fine-tuner sur données réelles (50-100 moteurs réels)
- Adaptation : Modèle génère sur distributions réelles bruitées

Bénéfice : Robustesse accrue, généralisation meilleure.

3. Prédiction Multivariate (Au-delà du RUL seul)

Actuel : Prédire un seul nombre (RUL global).

Amélioration : Prédire le **RUL par composant**

- RUL Fan (dégradation lame)
- RUL Compresseur HP (usure érosion)
- RUL Combusteur (usure thermique)
- RUL Turbine (fissuration)

Avantage : Maintenance planifiée au niveau de chaque sous-système (optimisation plus fine).

4. Explainability & XAI (Explainable AI)

Limitation : Random Forest est une "boîte noire" (peu explicable au mécanicien).

Approche XAI :

- SHAP (SHapley Additive exPlanations) : Quantifier la contribution de chaque capteur à chaque prédiction
- LIME (Local Interpretable Model-agnostic Explanations) : Expliquer localement autour d'une prédiction

Utilité : Le mécanicien comprend **pourquoi** le modèle recommande une maintenance, augmentant confiance et adoption.

8. Conclusion Générale

8.1 Résumé de la Démarche

Ce projet a suivi une **méthodologie de Data Science standard** appliquée au domaine critique de la maintenance prédictive aéronautique :

1. **EDA (Analyse Exploratoire)** : Exploration du dataset NASA C-MAPSS, identification des capteurs informatifs, corrélations physiquement cohérentes
2. **Feature Engineering** : Calcul du RUL, suppression de capteurs constants et de variables identifiants, normalisation Min-Max
3. **Modélisation** : Comparaison Régression Linéaire (baseline) vs Random Forest (avancé)
4. **Évaluation** : RMSE ≈ 41 cycles (~ 10 % erreur relative), performance acceptable pour prototype
5. **Discussion** : Analyse des risques et faisabilité en avion réel, identification des blocages (certification, données réelles, robustesse)

8.2 Résultats Clés

Aspect	Résultat
RMSE (Random Forest)	41.16 cycles
Erreur relative	~10 %
Capteur dominant	s11 (44.5 % importance)
Latence prédiction	< 10 ms (embarquable)
Données utilisées	20 631 observations entraînement, 13 896 validation
Modèle déployable immédiatement	Oui (Regression Linéaire), avec limitations
Modèle productionnisable aéronautique	Non (nécessite données réelles + certification)

8.3 Intérêt de l'IA en Maintenance Aéronautique

Enjeu économique :

- Coûts maintenance = 10-15 % coûts d'exploitation
- Grâce à la prédiction RUL : **réduction de 20-30 %** possible (moins d'immobilisations, moins de remplacements inutiles)
- Pour une compagnie aérienne 500 aéronefs : **économies = 500M€ annuels** (estimé conservateur)

Enjeu de sécurité :

- Prédiction RUL fiable = **panne anticipée** (pas de défaillance en vol)
- Maintenance en base, pas en urgence → Processus plus rigoureux, moins d'erreurs
- Risque incident réduit, conformité réglementaire accrue

Enjeu stratégique :

- Constructeurs moteurs (Safran, GE) développent des **moteurs connectés** (Internet of Things)
- Avionique future (ACARS, Cloud Computing) : **transmission temps réel** des données capteurs
- IA et Big Data : **différenciateur compétitif** majeur pour compagnies aériennes et mainteneurs

8.4 Conclusion Finale

Verdict : Ce projet démontre la **viabilité technique** de la maintenance prédictive par IA en aéronautique. Le modèle Random Forest atteint une **performance acceptable** (RMSE ~41 cycles) avec une **latence acceptable** (< 10 ms).

Cependant, le chemin vers une **intégration production** demande :

- Collecte de **données réelles** (pas synthétiques)
- **Certification aéronautique** rigoureuse (DO-254/DO-178C)
- **Audit de robustesse** face aux anomalies (bruits, défaillances capteur)
- **Deep Learning** et **Transfer Learning** pour améliorer précision (RMSE < 20 cycles)

Horizon 3-5 ans : Les technologies et standards existent ; la majorité des aéronefs commerciaux disposeront de **maintenance prédictive IA embarquée**, réduisant drastiquement les coûts et améliorant la sécurité aérienne mondiale.

Annexes

A. Références Scientifiques

- [1] Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). Damage propagation modeling for aircraft engine run-to-failure simulation. In Proceedings of the International Conference on Prognostics and Health Management (PHM). IEEE.
- [2] Zio, E., & Peloni, G. (2011). Particle filtering prognostic performance for seeded fault run-to-failure simulated data. *International Journal of Prognostics and Health Management*, 2(1), 1–13.
- [3] Lei, Y., Yang, B., Jiang, X., Jiao, F., Li, N., & Sommerfeld, T. (2020). Applications of structural health monitoring for aircraft maintenance. *Sensors*, 20(22), 6542.
- [4] Sikorska, J. Z., Hodkiewicz, M., & Biwater, L. (2011). Prognostic modelling options for remaining useful life estimation by industry. *Mechanical Systems and Signal Processing*, 25(5), 1803–1836.
- [5] NASA Ames Research Center. C-MAPSS Dataset. <https://c3.nasa.gov/dashlink/datasets/>

B. Standards Aéronautiques Cités

- **DO-254** (RTCA) : Design Assurance Guidance for Airborne Hardware
- **DO-178C** (RTCA) : Software Considerations in Airborne Systems and Equipment Certification
- **AS9100** (SAE) : Quality Management Systems for Aerospace, Defense and Related Organizations
- **EASA CS-E** : Certification Specification for Aircraft Engines
- **FAA 14 CFR Part 33** : Airworthiness Standards - Aircraft Engines

Rapport rédigé par : INassira FAHFOUHI & Noura KAZDARI

Date : 22 Décembre 2025

Institution : ENSA Safi | Département GINF | GATE3